## Forest Guided smoothing

이동균

November 25, 2021

### 목차

- 1. Introduction
- 2. Forest-Guided Smoothers
- 3. Confidence Intervals
- 4. Exploring the Forest
- 5. Examples

#### **Abstract**

- Randomforest 출력값, Spatially adaptive bandwidth matrice를 사용하여 local smoother 를 정의.
- Smoother는 forest의 유연성을 가지면서 ,선형 Smoother이므로 해석하기가 쉬워진다.
- bias correction, confidence interval 등도 이용가능.

#### 1. Introduction

Randomforest는 비모수 회귀 분석으로써 정확한 방법이지만 해석이 어렵다는 단점이 있다. 따라서, Standard error, confidence interval 등을 구하는데 어려움이 있다.

이 논문에서는 spatially adaptive local linear smoother를 구성하여 forest 의 값을 근사시킨다.

$$(X_1, Y_1), ..., (X_n, Y_n) \sim P$$

where  $Y_i \in R$  and  $X_i \in R^d$ ,  $\mu(x) = E(Y|X=x)$ , 그리고 d < n 가정할 때,

$$\hat{\mu}_{RF}(x) = \frac{1}{B} \sum_{j=1}^{B} \hat{\mu}_{j}(x)$$

 $\hat{\mu}_{RF}(x)$ 를 다른 임무에도 사용되는 다루기 쉬운 forest에 대한 근사치로 추정

$$\hat{\mu}_{RF}(x) = \sum_{i=1}^{n} w_i(x) Y_i$$

where  $w_i(x) \geq 0$  ,  $\sum_i w_i(x) = 1$ 

데이터를  $D_1$  and  $D_2$ 를 분할하고 각각의 사이즈가 n이라고 가정.  $D_1$  에서 bandwidth matrix 구성

$$H_x = \left(\frac{1}{n} \sum_{i} w_i(x) (X_i - x) (X_i - x)^T\right)^{1/2}$$
 (1)

K는 spherically symmetric kernel 이고 아래와 같이 정의한다.

$$K(x; H_x) = |H_x|^{-1} K(H_x^{-1} x).$$

여기서 bandwidth matrices의 하나의 parameter family를 정의한다.  $\Xi=\{hH_x:h>0,x\in R^d\}$ 

그리고 forest guided loce linear smoother (FGS) 정의한다. local linear smoother는 아래식을 최소화하는  $\hat{\mu}_h(x)=\hat{\beta}_0(x)$ 를 찾는다.

$$\sum_{i} (Y_i - \beta_0(x) - \beta(x)^T (X_i - x))^2 K(X_i - x; hH_x).$$


$$\hat{\mu}_h(x) = e_1^T (X_x^T W_x X_x)^{-1} X_x^T W_x Y = \sum_i \ell_i(x; h H_x) Y_i$$

where

$$X_x = \begin{bmatrix} 1 & (X_1 - x)^T \\ \vdots & \vdots \\ 1 & (X_n - x)^T \end{bmatrix}$$

$$W_x \leftarrow W_x(i,i) = K(X_i - x; hH_x), e_1 = (1,0,...,0)^T$$
 인 대각행렬

$$\ell_i(x; hH_x) = e_1^T (X_x^T W_x X_x)^{-1} X_x^T W_x$$
 (2)



 $\sigma^2(x) = Var(Y|X=x)$  를 추정해서 standard error를 구할 수 있다.

 $\sigma^2$ 을 추정하는 방법으로는 forest 로부터 잔차  $r_i=Y_i-\hat{\mu}_RF(X_i)$ 를 구한 후,  $r_i^2$ 을 반응변수,  $X_i$ 를 설명변수로 한 Random forest 모델로  $r_i^2$ 을 추정하는 방법을 사용한다.

위에서 추정한  $\hat{\sigma}^2(x)$ 는 분산을 과소추정하는 경향이 있으므로  $\hat{\sigma}(x)$  대신  $c\hat{\sigma}(x)$  를 사용한다.

$$H_x \equiv H_{n,x}$$
,  $\mu_2(K)I = \int uu^T K(u) du$ , and  $R(K) = \int K^2(u) du$ .

#### Assumptions

- (A1) K is compactly supported and bounded. All odd moments of K vanish.
- (A2)  $\sigma^2(x)$  is continuous at x and f is continuously differentiable. Also, the second order derivatives of  $\mu$  are continuous.
- Further, f(x) > 0 and  $\sigma^2(x) > 0$
- (A3)  $H_{n,x}$  is symmetric and positive definite. As  $n\to\infty$  we have  $n^{-1}|H_{n,x}|\to 0$  and  $H_{n,x}(i,j)\to 0$  for every i,j.
- (A4) There exists  $c_{\lambda}$  such that

$$\frac{\lambda_{max}(H_{n,x})}{\lambda_{min}(H_{n,x})} \le c_{\lambda}$$

앞의 (A1)-(A4) 조건 하에서 bias와 varariance를 아래와 같이 구한다.

$$B(x, H_x) = \frac{1}{2}\mu_2(K)tr(H_x^2 Hess(x)) + o_p(tr(H_x^2))$$
 (3)

$$V(x, H_x) = \frac{\sigma^2(x)R(X)}{n|H_x|f(x)}(1 + o_p(1)).$$
 (4)

bias에 bandwidth matrix를  $hH_x$ 를 사용하면 아래의 식을 만족한다.

$$B(x, hH_x) = h^2 c_n(x) + o_p(h^2 tr(H_x^2)).$$

for some  $c_n(x)$ 

(A4) There exist a sequence  $\phi_n \to 0$  and positive definite symmetric matrix  $C_x$  such that  $H_{n,x} \sim \phi_n C_x$  where  $\phi_n \asymp (1/n)^a$  for some 0 < a < 1 (A4) 가정을 통해  $B(x, hH_x) = h^2 c(x)/n^2 + o_p(h^2)$  으로 표현가능하다. 여기서 bias correction을 위해서는 더 강한 smoothness condition이 필요하다.

#### Assumptions

(A5) For some t, the  $t^{th}$  order derivatives of  $\mu$  are continuous and there exist function  $c_1(t),...c_t(x)$  such that, for any h>0,

$$B(x, hH_x) = \sum_{i=2}^{t} \frac{c_j(x)h^j}{n^{aj}} + o_p(\frac{1}{n^{at}})$$

Bias를 추정하기위해 아래와 같이 정의를 한다. b개의 bandwidth 선택  $h_1,h_2,...,h_b$ .

$$\begin{split} \hat{m} &= (\mu_{h_1}(x),...,\mu_{h_b}(x)).\\ \kappa_n &= (\mu(x),\kappa_{2,n}(x),...\kappa_{t,n}(x))^T \text{ where } \kappa_{j,n}(x) = c_j(x)/n^{aj} \end{split}$$

$$H = \begin{bmatrix} 1 & h_1^2 & h_1^3 & \cdots & h_1^t \\ 1 & h_2^2 & h_2^3 & \cdots & h_2^t \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & h_b^2 & h_b^3 & \cdots & h_b^t \end{bmatrix}$$

$$\hat{\kappa}_n = argmin_c ||\hat{m} - Hc||^2 = (H^T H)^{-1} H^T \hat{m}.$$

 $\hat{m} = LY$  where

$$L = \begin{bmatrix} \ell_1(x; h_1 H_x) & \ell_1(x; h_1 H_x) & \cdots & \ell_n(x; h_1 H_x) \\ \ell_1(x; h_2 H_x) & \ell_2(x; h_2 H_x) & \cdots & \ell_n(x; h_2 H_x) \\ \vdots & \vdots & \vdots & \vdots \\ \ell_1(x; h_b H_x) & \ell_2(x; h_b H_x) & \cdots & \ell_n(x; h_b H_x) \end{bmatrix}$$

$$\hat{\kappa}_n = (H^T H)^{-1} H^T L Y.$$

$$\hat{B}(x,h) = \sum_{j=2}^{t} \hat{\kappa}_{j,n}(x)h^{j} = g^{T}(H^{T}H)^{-1}H^{T}LY$$

where  $g = (0, h^2, ..., h^t)^T$ .

 $\hat{\kappa}_n$  의 첫번째 요소는  $\mu$  의 de-biased estimator 가 된다.

$$\mu^{\dagger}(x) = e_1^T (H^T H)^{-1} H^T L Y = \sum_i \tilde{\ell}_i(x)$$

where  $\tilde{\ell}(x) = e_1^T (H^T H)^{-1} H^T L$ .

 $\mu^{\dagger}(x)$  variance 와 esimated variance 는 아래와 같이 구한다.

$$Var[\mu^{\dagger}(x)] = \sum_{i} \tilde{\ell}_{i}^{2}(x)\sigma^{2}(X_{i})$$
$$s^{2}(x) = \sum_{i} \tilde{\ell}_{i}^{2}(x)\hat{\sigma}^{2}(X_{i})$$

여기서 CLT에 적용하기 위해서 bandwidth를 더 구체적으로 줄 필요가 있다. bandwidth를  $h_j=\alpha_j n^{-\gamma}$ , for j=1,2,...b, with  $0<\alpha_1<\dots<\alpha_b$  로 정하고, n에 의존하지 않는다고 가정한다.

#### Assumptions

Theorem 1 Assume that, conditional on  $D_1$ , assumptions (A1)-(A5) hold and:

(i) 
$$\sup_{x} |\hat{\sigma}^{2}(x) - \sigma^{2}(x)| \stackrel{p}{\to} 0$$
,

(ii) 
$$-a < \gamma < \frac{1-ad}{d}$$


Further, if t < d/2 we require a < 1/(d-2t). Also assume that Y is bounded and that b > t+1. Then

$$\frac{\mu^{\dagger}(x) - \mu(x)}{s(x)} \xrightarrow{d} N(0, 1).$$

$$P(\mu(x) \in C_n(x)) \to 1 - \alpha$$

where 
$$C_n(x) = \mu^{\dagger}(x) \pm z_{\alpha/2} s(x)$$

### 3. Confidence Intervals - Examples of Confidence Intervals



## 4. Exploring the Forest - Summarizing the Spatial Adaptivity of the Kernels

Wasserstein barycenter 개념을 도입한다.

먼저 두 분포 사이의 Warsserstein distance는 아래와 같이 구한다.

$$W_2^2(P_1, P_2) = \inf_J E_J[||X - Y||^2]$$

 $J = X \sim P_1$ 와  $Y \sim P_2$ 의 Joint distribution

특이 케이스로  $P_1=N(\mu_1,\sigma_1)$  and  $P_2=N(\mu_2,\sigma_2)$  일 때,

$$W_2^2(P_1, P_2) = ||\mu_1 - \mu_2||^2 + tr(\Sigma_1) + tr(\Sigma_2) - 2tr\{(\Sigma_1^{1/2} \Sigma_2 \Sigma_1^{1/2})^{1/2}\}$$

## 4. Exploring the Forest - Summarizing the Spatial Adaptivity of the Kernels

 $Q_x$ 의 Wasserstein barycenter는 아래의 식을 최소화(minimize)하는 distribution  $\overline{Q}$ 이다.

$$\int W^2(Q_x, \overline{Q}) dP_X(x)$$

예를 들어,  $N(\mu_1,1)$  and  $N(\mu_2,1)$  의 barycenter 는  $N((\mu_1+\mu_2)/2,1)$  이다. barycenter는 기존의 분포의 모양을 보존하는 분포가 나온다.

## 4. Exploring the Forest - Summarizing the Spatial Adaptivity of the Kernels

이제  $K(0,H_{x_i})$  들의 barycenter를 찾는 것이 우리의 목적이다. barycenter 는  $K(0,\overline{H})$  로 나오고,  $\overline{H}$  는 고유한 양정치 행렬 (unique positive definite matrix)

$$\overline{H} = \int (\overline{H}^{1/2} H_x \overline{H}^{1/2})^{1/2} dP_X(x) \tag{5}$$

 $\overline{H}$ 를 구하면, Frechet variance 도 아래와 같이 구할 수 있다.

$$V = \int W^2(\overline{H}, H_x) dP_X(x)$$
 (6)

# 4. Exploring the Forest - Comparing the Forest and the Smoother

Smoother를 쓰면서 얼마나 많은 Prediction accuracy의 손실을 보는지의 측도

$$\Gamma = E[(Y - \hat{\mu}(X))^2 - (Y - \hat{\mu}_{RF}(X))^2]$$

실제 데이터에서 계산은?

데이터를 각각 사이즈가  $m\approx n/4$  인 그룹  $D_1,D_2,D_3,D_4$  로 분할한 후,  $D_1$ 에서  $\hat{\mu}_{RF},D_2$ 에서  $\hat{\mu}$  를 추정한다.

$$\hat{\Gamma} = \frac{1}{m} \sum_{i \in D_3} r_i - \frac{1}{m} \sum_{i \in D_4} s_i$$

where  $r_i = (Y_i - \hat{\mu}_{RF}(X_i))^2$ ,  $s_i = (Y_i - \hat{\mu}(X_i))^2$ 

## 4. Exploring the Forest - Comparing the Forest and the Smoother

$$\sqrt{m}(\hat{\Gamma} - \Gamma) \stackrel{d}{\to} N(0, \tau^2)$$

$$au^2$$
 의 일치 추정량  $\hat{ au}=m^{-1}(\sum_i(r_i-\overline{r})^2+\sum_i(s_i-\overline{s})^2)$ 

 $\Gamma \supseteq$  confidence interval :

$$\hat{\Gamma} \pm z_{\alpha/2} \hat{\tau} / \sqrt{m}$$

## 4. Exploring the Forest - Multiresolution Local Variable Importance

local variable importance를 평가하는 가장 알려져 있는 방법은  $\mu$ 의 gradient를 추정하는 방법, 즉 local linear approximation을 사용하는 방법이다.

forest guided local linear smoother를 사용하여 gradient와 standard error를 추정할 수 있었다.

$$\beta_{h,j}(x) = \sum_{i} Y_i \ell_{ij}(x; hH_x)$$

where  $\ell_{ij}(x;hH_x)$ 는 벡터  $e_{j+1}^T(X_x^TW_xX_x)^{-1}X_xW_x$ 의 i번째 요소

## 4. Exploring the Forest - Multiresolution Local Variable Importance

 $\hat{\beta}_{h,j}$   $\supseteq$  standard error

$$se_{h,j}(x) = \sqrt{\sum_{i} \hat{\sigma}^{2}(X_{i})\ell_{ij}(x; hH_{x})}$$

 $1 - \alpha$  variability interval:

$$\hat{\beta}_{h,j}(x) \pm z_{\alpha/2} s e_{j,h}(x)$$

## 5. Examples - Synthetic Exmaple




Figure 5: Example (6). Effective bandwidths for each covariate.

(a) Barycenter of bandwidth matrix

(b) Effective bandwidths

#### 5. Examples - Synthetic Exmaple




Figure 6:  $\{\hat{\beta}_j(X_1), \dots, \hat{\beta}_j(X_n)\}$  for each covariate at four resolutions, h = 0.1, 0.5, 1, 2.




Figure 7: Variability intervals for  $\hat{\beta}_{1,h}(x), \cdots, \hat{\beta}_{4,h}(x)$  at x=(1/2,1/2,1/2,1/2,1/2).

## 5. Examples - Synthetic Exmaple

